Benchmark de datos personales

Entrega: miércoles 11 de noviembre de 2026 | Revisión evaluada: 0c3ea17

DELIA detectó 71 de 150 datos etiquetados (47,33 % de recall). Omitió 79 y generó 3 falsas alarmas. La principal limitación observada en este corpus es la cobertura del detector.

Qué se evaluó

Se ejecutó **detect()** de **backend/dlp/pii.py** sobre los 172 casos de **benchmarks/synthetic_pii_r3.jsonl**. El corpus ya venía en el repositorio y se generó por programa con datos sintéticos, sin información de clientes. Un acierto exige coincidencia exacta del tipo y la posición del dato.

Resultados por país

Grupo	Aciertos	Falsas alarmas	Omisiones	Precisión	Recall	F1
Chile	21	0	11	100 %	65,62 %	79,25 %
Colombia	32	3	14	91,43 %	69,57 %	79,01 %
México	3	0	27	100 %	10,00 %	18,18 %
Bolivia	3	0	27	100 %	10,00 %	18,18 %
Global	12	0	0	100 %	100 %	100 %
Total	**71**	**3**	**79**	**95,95 %**	**47,33 %**	**63,39 %**

Precisión: 71 de las 74 detecciones fueron correctas. **Recall:** 71 de los 150 datos esperados fueron encontrados. **F1:** media armónica de precisión y recall.

Dónde falla el detector

Encontró **12 de 20 RUT chilenos** y **12 de 20 NIT colombianos**. Las 3 falsas alarmas fueron de cédula colombiana. En México y Bolivia solo acertó correos. Omitió todos los CURP, RFC, CI y NIT bolivianos y todas las direcciones del corpus.

Alcance y siguiente paso

Se midió el detector aislado. La prueba del proxy completo corresponde al Issue #9. **Presidio, Cloudflare DLP y Google Model Armor: NO EJECUTADOS.** Para avanzar hacia el cierre del Issue #12, incorporar el evaluador al repositorio y guardar el reporte por país y tipo de dato junto con la revisión evaluada.

Cómo reproducir la evaluación

Python 3.14.4 | Git | Terminal de Ubuntu

Git identificó el commit evaluado. Python leyó el corpus con **json** y **pathlib**, agrupó los resultados con **collections** y ejecutó el detector real, que usa expresiones regulares y validadores. La evaluación corrió localmente, sin llamadas a OpenAI ni cobros de API.

Comando ejecutado

```
cd /home/benjamin/Descargas/DELIA &&
git rev-parse --short HEAD &&
python3 --version &&
PYTHONDONTWRITEBYTECODE=1 python3 - <<'PY'
import json
from collections import defaultdict
from pathlib import Path
from backend.dlp.pii import detect

counts = defaultdict(lambda: [0, 0, 0])
cases = Path("benchmarks/synthetic_pii_r3.jsonl").read_text(encoding="utf-8").splitlines()
for line in cases:
    case = json.loads(line)
    expected = {(e["type"], e["start"], e["end"]) for e in case["entities"]}
    found = set(detect(case["text"]))
    for i, entities in enumerate((expected & found, found - expected, expected - found)):
        for kind, _, _ in entities:
            for group in ("TOTAL", case["country"], f"{case['country']}/{kind}"):
                counts[group][i] += 1

print(f"Casos: {len(cases)}")
print("Grupo TP FP FN Precisión Recall F1")
for group, (tp, fp, fn) in sorted(counts.items()):
    ratios = [(tp, tp + fp), (tp, tp + fn), (2 * tp, 2 * tp + fp + fn)]
    print(group, tp, fp, fn, *(f"{n/d:.2%}" if d else "N/A" for n, d in ratios))
PY
```

Salida de la ejecución

```
0c3ea17
Python 3.14.4
Casos: 172
Grupo TP FP FN Precisión Recall F1
TOTAL 71 3 79 95.95% 47.33% 63.39%
```

Referencias

Issue #12 / alcance y criterios de aceptación

Documentación del benchmark y corpus sintético

Código del detector en la revisión evaluada

Issue #9 / sanitización en el flujo del proxy

Próximos pasos

Issue #12 | Reproducción, diagnóstico y comparación

1. Guardar el benchmark en el repositorio

Guardar el benchmark como **benchmarks/evaluate.py**. Así cualquiera del equipo puede repetir la prueba y obtener métricas por país y tipo de dato.

2. Revisar las omisiones y falsas alarmas

Revisar por qué se escaparon **8 de 20 RUT chilenos y 8 de 20 NIT colombianos**. Agrupar los fallos por formato y revisar también las **3 falsas alarmas de cédula colombiana** para identificar qué reglas conviene ajustar primero.

3. Probar los ajustes con ejemplos nuevos

Medir si sube el recall sin que aumenten demasiado las falsas alarmas. Priorizar **CURP, RFC y otros identificadores** según los países que el equipo decida cubrir.

4. Documentar la comparación externa

Probar **Presidio, Cloudflare DLP y Google Model Armor** cuando haya acceso, o registrar **NO EJECUTADO**, como permite el issue.